Universidad Libre Seccional Bogotá
Departamento de Ingeniería de Sistemas

Analisis y Justificacion
Parcial Segundo Corte
Reglas de Asociacion

Presentado por:
Johel Arias

Presentado a:
Ing Gustavo SantosVargas

Minería de Datos 2026-I
Bogotá D. C.

Tabla de Contenido

Capitulo 1. Introducción 7

Capitulo 2. Carga y descripción de los Datos 8

2.1. Fuente de los datos. 8

2.1.1. Explicación de las variables. 9

2.2. Configuraciones iniciales del proyecto. 10

2.3. Carga de datos. 11

Capitulo 3. Preprocesamiento y limpieza de datos 12

3.1. Normalizacion y tipado 14

3.2. Normalizacion de texto de productos. 15

3.2.1. Función normalize_product. 16

3.2.2. Función clean_and_split. 17

3.3. Codificacion One-Hot (Binarizacion) 19

3.4. Análisis Exploratorio (frecuencias) 21

Capitulo 4. Implementación del modelo 24

4.1. Definición de los parámetros. 24

4.2. Aplicación de ECLAT. 24

4.2.1. Función build_transactions. 25

4.2.2. Función run_eclat 26

Capitulo 5. Resultados 29

5.1. Reglas de asociación. 29

5.1.1. ECLAT — Reglas de Asociación 32

5.1.2. Heatmap de Lift 33

5.1.3. Red de afinidad 34

5.1.4. Distribucion de métricas de reglas ECLAT. 35

Capitulo 6. Intepretacion 36

6.1. Lecuta por estrato socioeconómico. 36

6.1.1. Estrato 1. 36

6.1.2. Estrato 2. 37

6.1.3. Estrato 3. 38

6.1.4. Estrato 4. 39

6.1.5. Soporte por producto y estrato socioeconómico 40

6.2. Lectura por grupo de edad. 41

6.2.1. Grupo 1. Menor de 18 años 41

6.2.2. Grupo 2. 18-25 años 42

6.2.3. Grupo 3. 26-30 años 43

6.2.4. Grupo 4. 31-60 años 44

6.2.5. Soporte por producto y grupo de edad 45

Capitulo 7. Referencias 46

Tabla de tablas

Tabla 1. Descripcion de variables encontradas en el dataset utilizado. Fuente propia 9

Tabla 2. Tabla de parametros del modelo. Fuente propia 24

Tabla 3. Reglas relevantes por afinidad y por puntaje. Fuente propia 31

Tabla 4. Reglas relevantes por afinidad y por puntaje. Fuente propia 32

Tabla de Ilustraciones

Ilustración 1. Archivo excel correspondiente a los resultados de la encuesta de mercado (Dataset) utilizado. Fuente propia 8

Ilustración 2. Importacion de librerías necesarias. Fuente propia 10

Ilustración 3. Variables de configuracion del proyecto. Fuente propia 10

Ilustración 4. Creacion del modelo de procesamiento de lenguaje natural para la interprestacion de productos. Fuente propia 11

Ilustración 5. Cargue de datos a traves de lectura de archivo excel. Fuente propia 11

Ilustración 6. Objetos de renoimbramiento de columnas del dataset. Fuente propia 12

Ilustración 7. Arreglo de nombramiento de columnas para binarizacion. Fuente propia 12

Ilustración 8. Arreglo de nombramiento de columnas demográficas para posterior uso. Fuente propia 13

Ilustración 9. Intervalos de edad para categorizacion de grupo_edad. Fuente propia 14

Ilustración 10. Ajuste de tipado en columnas de edad y gasto, y adicion de nueva columna grupo_edad. Fuente propia..... 14

Ilustración 11. Funcion de normalize_product. Fuente propia 16

Ilustración 12. Funcion clean_and_split. Fuente propia 17

Ilustración 13. Dataset con productos normalizados. Fuente propia. 18

Ilustración 14. Lista de comparacion de productos originales a normalizados. Fuente propia. ... 18

Ilustración 15. Dataframe de codificacion One-Hot (Binarizacion). Fuente propia..... 19

Ilustración 16. Dataframe completo con productos binarizados. Fuente propia..... 20

Ilustración 17. Analisis exploratorio de frecuencias. Fuente propia..... 21

Ilustración 18. Transformacion a formato transaccional y calculo de soporte. Fuente Propia. 22

Ilustración 19. Transacciones creadas por los productos estandarizados. Fuente propia 25

Ilustración 20. Funcion build_transactions. Fuente propia 25

Ilustración 21. Construccion de transacciones y calculo de sporte en la funcion run_eclat. Fuente propia 26

Ilustración 22. Creacion de los itemsets del eclat a traves de indices. Fuente propia 27

Ilustración 23. Primeros 20 conjuntos de itemset creados a traves de la implementacion del ECLAT. Fuente propia..... 28

Ilustración 24. Metricas utilizadas en las reglas de asociacion encontradas. Fuente propia 29

Ilustración 25. Reglas relevantes de acuerdo a las metricas utilizadas. Fuente propia..... 30

Ilustración 26. Heatmap de lift de lascombinaciones mas fuertes. Fuente propia..... 33

Ilustración 27. Red de afinidad de las reglas de asociacion. Fuente propia..... 34

Ilustración 28. Distribucion de métricas de las reglas ECLAT. Fuente propia 35

Ilustración 29. Distribucion de reglas para el estrato 1. Fuente propia..... 36

Ilustración 30. Distribucion de reglas para el estrato 2. Fuente propia..... 37

Ilustración 31. Distribucion de reglas para el estrato 3. Fuente propia..... 38

Ilustración 32. Distribucion de reglas para el estrato 4. Fuente propia..... 39

Ilustración 33. Soporte por producto y estrato socioeconomico. Fuente propia..... 40

Ilustración 34. Distribucion de reglas para el grupo de edad Menor a 18. Fuente propia 41

Ilustración 35. Distribucion de reglas para el grupo de edad entre 18 y 25 años. Fuente propia . 42

Ilustración 36. Distribucion de reglas para el grupo de edad entre 26 y 30 años. Fuente propia . 43

Ilustración 37. Soporte por producto y grupo de edad. Fuente propia..... 45

Capitulo 1. Introducción

En este documento, se presenta el analisis y justificación correspondiente a la actividad practica del parcial del segundo corte de Reglas de Asociación.

En el cual se realizo los procesos de cargue y descripción de datos, preprocesamiento, implementación del modelo ECLAT, se evidencias los resultado, la interpretación manteniendo la calidad del código Python desarrollado en el entorno de Jupyter de forma local.

Es posible observar repositorio de almacenamiento del proyecto desarrollado a través del siguiente enlace.

Arias S. (2026). Parcial 2 Practico - Reglas de Asociacion (Mineria de Datos). GitHub. https://github.com/5arSanti/data-mining-eclat

O de igual forma, es posible evidenciarlo a través del siguiente colab.

Arias S. (2026). Parcial 2 Practico - Reglas de Asociacion (Mineria de Datos). https://colab.research.google.com/drive/1FRWW8kjhHL4VHf2WGZKlj0CFpA0l365h?usp=sharing

Capitulo 2. Carga y descripción de los Datos

2.1. Fuente de los datos.

Para esta parte practica del parcial, se utilizo el dataset resultado de una encuenta de mercado realizada a 200 individuos diferentes entre los cuales se incluye a los estudiantes de la materia de minería de datos del grupo MD (2026-1) de Ingenieria de Sistemas de la Universidad Libre de Colombia.

Esta encuesta cuensta con una seria de preguntas demográficas y de los tipos de productos que compra de forma regular al momento de realizar una misión de compra de reabastecimiento.

Arias S. (2026). Resultados de encuesta de mercado (Dataset) – Minería de Datos. https://1drv.ms/x/c/9cd239359a0de8d6/IQBs8Cy0d-eCT4SbIBajGUnuAd7EB6KiTgNPsAB1CxjXUu4?e=HzwyBw

Ilustración 1. Archivo excel correspondiente a los resultados de la encuesta de mercado (Dataset) utilizado. Fuente propia

	A	B	C	D	E	F	G	H	I	J	K	L	
1	Marca temporal	EDAD	GENERO	ESTRATO NSE	CIUDAD DE ORIGEN	Con quien vive actu	Numero de	Quien realiza las c	Tu misión de con	Lugar principal de compra	Presupuesto Mensu	Alimentos Básicos	Prote
2	2026-04-01 8:00:00	18	Masculino	E2	Bogotá	Padres	5	Otra persona	Quincenal	Supermercado (Exito, Jumbo, Etc	700000	Pastas, Lentejas	Atun
3	2026-04-01 13:42:00	21	Femenino	E3	Medellín	Padres	4	Otra persona	Mensual	Hard Discount (D1, ARA, etc)	1000000	Frijoles, Pastas	Pesca
4	2026-04-01 14:54:00	20	Masculino	E3	Santa Marta	Padres	2	Compartido	Quincenal	Tienda de Barrio	500000	Pastas	Huev
5	2026-04-01 15:21:00	25	Masculino	E3	Medellín	Familia	6	Compartido	Mensual	Supermercado (Exito, Jumbo, Etc	2000000	Lentejas, Frijoles, Harinas, Pastas	Carne
6	2026-04-01 21:55:00	21	Masculino	E3	Bogotá	Familia	4	Yo	Mensual	Supermercado (Exito, Jumbo, Etc	1200000	Lentejas	Pollo
7	2026-04-02 7:15:00	24	Masculino	E3	Bogotá	Padres	5	Otra persona	Mensual	Hard Discount (D1, ARA, etc)	1200000	Pastas, Arroz, Harinas, Lentejas, Ga	Carne
8	2026-04-02 9:24:00	23	Masculino	E3	Cali	Padres	5	Compartido	Quincenal	Supermercado (Exito, Jumbo, Etc	1500000	Garbanzos, Lentejas	Huev
9	2026-04-02 10:50:00	18	Femenino	E3	Bogotá	Familia	2	Yo	Diario	Tienda de Barrio	1200000	Frijoles, Harinas, Pastas, Arroz, Ga	Pollo
10	2026-04-02 17:22:00	25	Femenino	E3	Cali	Padres	3	Yo	Mensual	Supermercado (Exito, Jumbo, Etc	1200000	Arroz, Pastas, Frijoles	Carne
11	2026-04-02 18:29:00	25	Femenino	E3	Bogotá	Familia	6	Compartido	Quincenal	Plaza de mercado	1500000	Lentejas, Arroz, Frijoles, Harinas	Pollo
12	2026-04-03 7:47:00	19	Masculino	E3	Bogota D.C	Padres	4	Otra persona	Mensual	Supermercado (Exito, Jumbo, Etc	700000	Pastas, Frijoles	Carne
13	2026-04-03 12:41:00	21	Masculino	E2	Bogotá	Familia	3	Otra persona	Quincenal	Supermercado (Exito, Jumbo, Etc	1200k	Pastas, Harinas	Pollo
14	2026-04-03 13:40:00	19	Masculino	E3	Bogota	Padres	2	Otra persona	Semanal	Hard Discount (D1, ARA, etc)	700000	Harinas, Garbanzos	Pesca
15	2026-04-03 18:57:00	18	Masculino	E4	Bogotá D.C.	Familia	5	Compartido	Quincenal	Supermercado (Exito, Jumbo, Etc	1000000	Garbanzos, Lentejas, Pastas	Carne
16	2026-04-03 22:48:00	22	Masculino	E3	Bogota	Padres	3	Otra persona	Quincenal	Tienda de Barrio	500000	Lentejas, Garbanzos, Arroz	Pesca
17	2026-04-04 7:05:00	40	Masculino	E3	Bogota	Familia	4	Compartido	Mensual	Supermercado (Exito, Jumbo, Etc	1200000	Lentejas, Pastas	Carne
18	2026-04-04 9:11:00	24	Masculino	E4	Santa Marta	Padres	5	Compartido	Semanal	Supermercado (Exito, Jumbo, Etc	2000000	Frijoles, Pastas, Harinas, Lentejas,	Pollo
19	2026-04-04 11:25:00	21	Masculino	E2	mani casanare	Familia	4	Otra persona	Quincenal	Hard Discount (D1, ARA, etc)	500000	Frijoles, Arroz	Huev
20	2026-04-04 15:58:00	19	Masculino	E3	Bogota	Padres	7	Compartido	Quincenal	Hard Discount (D1, ARA, etc)	1000000	Arroz, Frijoles	Pollo
21	2026-04-04 21:21:00	19	Masculino	E3	Bogota	Padres	8	Compartido	Mensual	Tienda de Barrio	700k	Arroz, Harinas, Frijoles, Lentejas	Carne
22	2026-04-04 21:49:00	25	Masculino	E1	Cartagena	Familia	5	Compartido	Quincenal	Supermercado (Exito, Jumbo, Etc	1200000	Frijoles, Lentejas, Pastas, Harinas	Carne
23	2026-04-05 7:12:00	25	Masculino	E3	Bogota	Familia	4	Otra persona	Mensual	Hard Discount (D1, ARA, etc)	600000	Garbanzos, Arroz, Frijoles	Carne
24	2026-04-05 13:33:00	21	Masculino	E2	Bogota	Padres	4	Otra persona	Semanal	Hard Discount (D1, ARA, etc)	1500k	Arroz, Frijoles, Lentejas, Pastas	Carne
25	2026-04-05 19:20:00	22	Masculino	E4	Bogotá	Familia	6	Compartido	Quincenal	Hard Discount (D1, ARA, etc)	1200000	Lentejas	Pesca
26	2026-04-06 7:34:00	19	Masculino	E3	Bogota	Padres	2	Compartido	Semanal	Hard Discount (D1, ARA, etc)	1200000	Garbanzos	Pollo
27	2026-04-06 11:23:00	21	Masculino	E4	Bogotá	Familia	2	Compartido	Semanal	Tienda de Barrio	600000	Arroz	Huev
28	2026-04-06 13:30:00	22	Masculino	E3	Medellín	Padres	4	Compartido	Quincenal	Supermercado (Exito, Jumbo, Etc	1700000	Garbanzos, Arroz, Pastas, Lentejas	Carne
29	2026-04-06 17:34:00	22	Femenino	E4	Bogota	Padres	4	Otra persona	Quincenal	Supermercado (Exito, Jumbo, Etc	1000000	Arroz, Garbanzos, Lentejas	Carne
30	2026-04-06 22:50:00	18	Masculino	E4	Bogota	Familia	4	Yo	Diario	Supermercado (Exito, Jumbo, Etc	1800000	Arroz, Pastas, Frijoles, Garbanzos,	Huev
31	2026-04-07 7:51:00	23	Masculino	E3	Bogotá	Familia	2	Compartido	Mensual	Hard Discount (D1, ARA, etc)	400000	Arroz, Pastas, Lentejas	Carne
32	2026-04-07 8:09:00	19	Masculino	E4	Bogotá	Padres	3	Otra persona	Semanal	Hard Discount (D1, ARA, etc)	700000	Pastas, Frijoles	Atun,
33	2026-04-07 14:52:00	21	Femenino	E4	Bogotá	Padres	6	Otra persona	Mensual	Hard Discount (D1, ARA, etc)	1000000	Pastas, Harinas, Lentejas	Atun,
34	2026-04-07 16:28:00	18	Femenino	E4	Bogotá	Familia	4	Otra persona	Mensual	Supermercado (Exito, Jumbo, Etc	1200000	Frijoles, Arroz, Harinas, Garbanzos	Carne

2.1.1. Explicación de las variables.

A continuación, se puede encontrar la explicación de las variables (Columnas) presentes en el dataset.

Tabla 1. Descripcion de variables encontradas en el dataset utilizado. Fuente propia

Variable	**Descripcion**
EDAD	Edad del encuestado expresada en años.
GENERO	Identidad de género
ESTRATO NSE	Estado socieconomico del hogar según la clasificación establecida
CIUDAD DE ORIGEN	Ciudad de origen del encuestado
Con quien vive actualmente	Personas con las que convive el encuestado
Numero de personas en el hogar	Total de personas con las que vive el encuestado
Quien realiza las compras en el Hogar	Quien realiza las compras del hogar
Tu misión de compra es abastecer tu hogar. Con que frecuencia lo haces.	La frecuencia con la que el encuestado realiza compras para abastecer el hogar
Lugar principal de compra	Establecimiento donde el encuestado realiza sus compras
Presupuesto Mensual aproximado	Valor estimado de dinero destinado mensualmente a las compras
Alimentos Básicos	Lista de productos básicos
Proteinas	Proteinas consumidas o compradas
Bebidas	Tipos de bebidas compradas
Snacks y otros	Tipos de snacks u otros productos comprados
Delikatessen	Tipos de productos especiales o gourmet comprados
Aseo para el Hogar	Tipos de productos de aseo para el hogar comprados
Aseo Personal	Tipos de productos de aseo personal comprados
ultima	Otro tipo de productos comprados

2.2. Configuraciones iniciales del proyecto.

Para la creacion de este proyecto se utilizaron librerías como pandas, openpyxl, spacy, matplotlib, seaborn, networkx y scikit-learn. Por lo tanto se comienza con la importación de las librearias necesarias.

Ilustración 2. Importacion de librerías necesarias. Fuente propia

Se realiza la importacion de librerías necesarias

```python
# Propósito: importar librerias, definir parámetros globales y preparar el entorno del análisis.
from __future__ import annotations

import re
import unicodedata
from itertools import combinations
from pathlib import Path

import matplotlib.pyplot as plt
import networkx as nx
import pandas as pd
import seaborn as sns
import spacy
from sklearn.preprocessing import MultiLabelBinarizer
```

[32] ✓ 0.2s Python

Y posteriormente se definen variables de configuración del proyecto de forma global. Entre ellas, se define la ruta ubicación del dataset utilizado, el nombre de la hoja a procesar, los valores de corte y nombres de etiquetas para la definición de la categorización por edades, y finalmente la ruta junto al nombre del dataset binarizado.

Ilustración 3. Variables de configuracion del proyecto. Fuente propia

```python
# — Configuración global ————————————————————
DATASET_PATH = Path('data/dataset.xlsx')
SHEET_NAME = 'Respuestas de formulario 1'
EDAD_BINS = [0, 18, 25, 30, 60, 100]
EDAD_LABELS = ['Menor de 18', '18-25', '26-30', '31-60', '61+']
OUTPUT_PATH = Path('df_procesado.xlsx')
```

Asi mismo, se instancia un modelo de procesamiento de lenguaje natural, descargado desde la librería de spicy, cuya función es procesar los productos encontrados en el dataset a fin de normalizar cada uno de ellos, con el fin de eliminar ruido en los productos existentes, y únicamente categorizar en los productos que realmente existen.

Ilustración 4. Creacion del modelo de procesamiento de lenguaje natural para la interprestacion de productos. Fuente propia

```
nlp = spacy.load('es_core_news_sm', disable=['parser', 'ner'])
```

2.3. Carga de datos.

En la fase de carga de datos, se carga el dataset a través de la lectura del archivo excel en la hoja correspondiente. De tal forma que es posible evidenciar el dataset como dataframe de pandas.

Ilustración 5. Cargue de datos a traves de lectura de archivo excel. Fuente propia

Por lo tanto, inicialmente se lee el dataset en excel para comenzar a trabajar los datos

```
# Propósito: ubicar la ruta efectiva del dataset y validar su existencia antes de cargarlo.
dataset_file = DATASET_PATH
df = pd.read_excel(dataset_file, sheet_name=SHEET_NAME)
df.head()
```

✓ 0.0s Python

	Marca temporal	EDAD	GENERO	ESTRATO NSE	CIUDAD DE ORIGEN	Con quien vive actualmente	Numero de personas en el hogar	Quien realiza las compras en el Hogar	Tu misión de compra es abastecer tu hogar. Con que frecuencia lo haces.	Lugar principal de compra	Presupuesto Mensual aproximado	Alimentos Básicos	Proteinas	Bebidas	Snacks y otros	Delikatessen	Aseo para el Hogar	Aseo Personal	ultima
0	2026-04-01 08:00:00	18	Masculino	E2	Bogotá	Padres	5	Otra persona	Quincenal	Supermercado (Exito, Jumbo, Etc)	700000	Pastas, Lentejas	Atun	Te, Leche	ninguno	ninguno	Papel Higienico, Suavizantes, Blanqueadores	Talcos, Lociones - Colonias	te, lavaloza, desinfectante, leche, suavizante...
1	2026-04-01 13:42:00	21	Femenino	E3	Medellín	Padres	4	Otra persona	Mensual	Hard Discount (D1, ARA, etc)	1000000	Frijoles, Pastas	Pescados, Pollo, Carne de Res	Café	ninguno	Salsas, Jamon	Blanqueadores, Limpiavidrios, Limpiapiso	Shampoo, Jabon tocador, Acondicionador, Talcos	Carne de Res\npan\nFrijoles\npasta\nJabon toca...
2	2026-04-01 14:54:00	20	Masculino	E3	Santa Marta	Padres	2	Compartido	Quincenal	Tienda de Barrio	500000	Pastas	Huevos, Carne de Res	Leche, Gaseosa	ninguno	Otros Embutidos	Cera, Papel Higienico, Suavizantes, Servilletas	Jabon tocador, Crema dental, Acondicionador	detergente, blanqueador, Papel Higienico, Cera...
3	2026-04-01 15:21:00	25	Masculino	E3	Medellín	Familia	6	Compartido	Mensual	Supermercado (Exito, Jumbo, Etc)	2000000	Lentejas, Frijoles, Harinas, Pastas	Carne de Res, Pollo	Leche, Café	ninguno	Salsas	Detergente, Blanqueadores, Cera, Desinfectante...	Protección Femenina, Jabon tocador, Hilo Denta...	leche, Jabon tocador, pan, Carne de Res, arroz...
4	2026-04-01 21:55:00	21	Masculino	E3	Bogotá	Familia	4	Yo	Mensual	Supermercado (Exito, Jumbo, Etc)	1200000	Lentejas	Pollo, Huevos	Agua	ninguno	Salsas, Quesos, Cervezas	ambientadores, Blanqueadores, Desinfectante, L...	Crema dental, Protección Femenina, Enjuague Bu...	aceite\nProtección Femenina\nSuavizantes\nBlan...

Capitulo 3. Preprocesamiento y limpieza de datos

El preprocesamiento de datos para el dataset parte de la definición de 3 objetos condiferentes fines. El primero de ellos define el renombramiento de las columnas del dataset, para un uso mas sencillo y controlado.

Ilustración 6. Objetos de renoimbramiento de columnas del dataset. Fuente propia

```
column_rename_map = {
    "marca temporal": "fecha",
    "edad": "edad",
    "genero": "genero",
    "estrato nse": "estrato_nse",
    "ciudad de origen": "ciudad_origen",
    "con quien vive actualmente": "quien_vive",
    "numero de personas en el hogar": "num_personas",
    "quien realiza las compras en el hogar": "quien_compra",
    "tu misión de compra...": "mision_compra",
    "lugar principal de compra": "canal_compra",
    "presupuesto mensual aproximado": "gasto",
    "alimentos básicos": "alimentos_basicos",
    "proteinas": "proteinas",
    "bebidas": "bebidas",
    "snacks y otros": "snacks",
    "delikatessen": "delikatessen",
    "aseo para el hogar": "aseo_hogar",
    "aseo personal": "aseo_personal",
    "ultima": "otros",
}
```

Luego, se define un arreglo que permite indicar las columnas de las cuales se van a extraer los productos para su binarizacion correspondiente.

Ilustración 7. Arreglo de nombramiento de columnas para binarizacion. Fuente propia

```
rows_to_cols = [
    "alimentos_basicos",
    "proteinas",
    "bebidas",
    "snacks",
    "delikatessen",
    "aseo_hogar",
    "aseo_personal",
    "otros",
]
```

Finalmente se define el arreglo con las columnas demográficas existentes en el dataset. De tal modo que es posible exatraer la informacion de estas columnas para su posterior uso.

Ilustración 8. Arreglo de nombramiento de columnas demográficas para posterior uso.

Fuente propia

```
cols_demograficas = [
    "fecha",
    "edad",
    "genero",
    "estrato_nse",
    "ciudad_origen",
    "quien_vive",
    "num_personas",
    "quien_compra",
    "mision_compra",
    "canal_compra",
    "gasto",
    "grupo_edad",
]
```

3.1. Normalizacion y tipado

Posterior a la definición de las columnas a trabajar, se realiza el proceso de normalización de tipos. Por lo tanto, para las columnas de edad y gasto se ajustan los tipos de tipo numérico y se crea una nueva columna denominada grupo_edad que agrega una categoria de edad a cada fila del dataset dada por EDAD_BINS y EDAD_LABELS.

Ilustración 9. Intervalos de edad para categorizacion de grupo_edad. Fuente propia

```
EDAD_BINS = [0, 18, 25, 30, 60, 100]
EDAD_LABELS = ['Menor de 18', '18-25', '26-30', '31-60', '61+']
```

Donde la asignacion de la cateogria depende de en donde se encuentre el valor de edad de cada fila contrastado frente al rango de edades definidor. Por Ejemplo, si la edad se encuentra entre 0 y 18 años, la categoria correspondiente es “Menor de 18”.

Ilustración 10. Ajuste de tipado en columnas de edad y gasto, y adicion de nueva columna grupo_edad. Fuente propia

```
Shape: (200, 20)
<class 'pandas.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 20 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   fecha             200 non-null    datetime64[us]
 1   edad              200 non-null    int64
 2   genero            200 non-null    str
 3   estrato_nse       200 non-null    str
 4   ciudad_origen     200 non-null    str
 5   quien_vive        200 non-null    str
 6   num_personas      200 non-null    int64
 7   quien_compra      200 non-null    str
 8   mision_compra     200 non-null    str
 9   canal_compra      200 non-null    str
 10  gasto             185 non-null    float64
 11  alimentos_basicos 200 non-null    str
 12  proteinas         200 non-null    str
 13  bebidas           200 non-null    str
 14  snacks            200 non-null    str
 15  delikatessen      200 non-null    str
 16  aseo_hogar        200 non-null    str
 17  aseo_personal     200 non-null    str
 18  otros             200 non-null    str
 19  grupo_edad        200 non-null    category
dtypes: category(1), datetime64[us](1), float64(1), int64(2), str(15)
memory usage: 30.2 KB
```

num_personas	quien_compra	mision_compra	canal_compra	gasto	alimentos_basicos	proteinas	bebidas	snacks	delikatessen	aseo_hogar	aseo_personal	otros	grupo_edad
5	Otra persona	Quincenal	Supermercado (Exito, Jumbo, Etc)	700000.0	Pastas, Lentejas	Atun	Te, Leche	ninguno	ninguno	Papel Higienico, Suavizantes, Blanqueadores	Talcos, Lociones - Colonias	te, lavaloza, desinfectante, leche, suavizante...	Menor de 18
4	Otra persona	Mensual	Hard Discount (D1, ARA, etc.)	1000000.0	Frijoles, Pastas	Pescados, Pollo, Carne de Res	Café	ninguno	Salsas, Jamon	Blanqueadores, Limpiavidrios, Limpiapiso	Shampoo, Jabon tocador, Acondicionador, Talcos	Carne de Res\npan\nFrijoles\npasta\nJabon toca...	18-25
2	Compartido	Quincenal	Tienda de Barrio	500000.0	Pastas	Huevos, Carne de Res	Leche, Gaseosa	ninguno	Otros Embutidos	Cera, Papel Higienico, Suavizantes, Servilletas	Jabon tocador, Crema dental, Acondicionador	detergente, blanqueador, Papel Higienico, Cera...	18-25

3.2. Normalizacion de texto de productos.

Para el proceso de normalizacion de texto, enfocado principalmente en la normalizacion de los productos encontrados, se realizo un proceso de limpieza y estandarizacion de cada uno de los productos. En este caso, se definen principalmente dos funciones (normalize_product y clean_and_split) que permiten obtener la version limpia y agrupada de cada product.

Estas dos funciones forman un flujo cuyo objetivo es limpiar, organizar y estandarizar los productos escritos por los usuarios, y además dejar evidencia de cómo cambió cada dato en el proceso. Por lo tanto a traves de un registro definido como comparison_rows, se va guardando cada producto tal como fue escrito originalmente y cómo quedó después de limpiarlo.

3.2.1. Función normalize_product.

La función normalize_product se encarga de tomar cada palabra o producto individual y llevarlo a una forma más uniforme.

Para lograrlo, simplifica la palabra a su forma base (por ejemplo, pasar de plural a singular) y luego aplica reglas definidas en un diccionario para unificar nombres (como convertir marcas en categorías) o eliminar valores que no aportan información. Esto o realiza a traves del modelo de procesamiento de lenguaje natural definido en la parte de configuraciones del proyecto

Ilustración 11. Funcion de normalize_product. Fuente propia

```python
def normalize_product(token: str) -> str | None:
    """Normaliza un token de producto con lematización + diccionario replace_map."""
    if not token or token == "ninguno":
        return None

    doc = nlp(token)
    lemma = doc[0].lemma_ if doc else token
    lemma = lemma.strip()

    result = replace_map.get(lemma, lemma)
    return result if result else None
```

3.2.2. Función clean_and_split.

La función clean_and_split trabaja sobre textos completos (como listas de mercado escritas en una sola celda). Esta función limpia el texto eliminando tildes, caracteres innecesarios y diferentes separadores, para convertir todo en una lista clara de productos individuales.

Después, cada producto pasa por el proceso de normalización. En este punto también se guarda la relación entre el valor original y el valor transformado, construyendo así una trazabilidad completa del cambio.

Ilustración 12. Funcion clean_and_split. Fuente propia

```python
def clean_and_split(text: str) -> list[str]:
    """Limpia texto crudo, separa productos y devuelve lista única normalizada.
       Además registra trazabilidad original vs normalizado."""

    if pd.isna(text) or not isinstance(text, str):
        return []

    text = unicodedata.normalize("NFKD", text)
    text = text.encode("ascii", "ignore").decode("utf-8", "ignore")
    text = text.lower()
    text = re.sub(r"[\n\r]+", ",", text)
    text = re.sub(r"-\s*", ",", text)
    text = re.sub(r";", ",", text)
    text = re.sub(r"\s{2,}", ",", text)
    text = re.sub(r",+", ",", text)

    tokens = [t.strip() for t in text.split(",") if t.strip()]
    tokens = [t for t in tokens if t != "ninguno"]

    normalized = []

    for t in tokens:
        norm = normalize_product(t)

        # Guardar trazabilidad (aunque sea None)
        comparison_rows.append({
            "original": t,
            "normalized": norm
        })

        if norm:
            normalized.append(norm)

    return sorted(set(normalized))
```

De esta forma, la estrucutra de productos final, queda completamente normalizada en estructuras de tipo arreglo one-hot, listas para el proceso de binarizacion.

Ilustración 13. Dataset con productos normalizados. Fuente propia.

De esta forma, la matriz de productos se transforma en columnas de productos one-hot con los productos completamente normalizados y agrupados

```python
# Propósito: transformar columnas de productos en matriz one-hot y consolidar base final.
processed = df[rows_to_cols].apply(lambda col: col.map(clean_and_split))
processed.head()
```

	alimentos_basicos	proteinas	bebidas	snacks	delikatessen	aseo_hogar	aseo_personal	otros
0	[lenteja, pasta]	[atun]	[leche, tú]	[]	[]	[blanqueador, papel, suavizante]	[colonia, loción, talco]	[atun, blanqueador, colonia, desinfectante, la...
1	[frijol, pasta]	[carne, pescado, pollo]	[cafe]	[]	[jamon, salsa]	[blanqueador, limpiapiso, limpiavidrio]	[acondicionador, jabon tocador, shampoo, talco]	[acondicionador, carne, frijol, fruta, jabon t...
2	[pasta]	[carne, huevo]	[gaseós, leche]	[]	[otro]	[cera, papel, servilleta, suavizante]	[acondicionador, crema, jabon tocador]	[arroz, atun, blanqueador, cera, crema, deterg...
3	[frijol, harina, lenteja, pasta]	[carne, pollo]	[cafe, leche]	[]	[salsa]	[blanqueador, cera, desinfectante, detergente,...	[colonia, hilo, jabon tocador, loción, perfumi...	[arroz, carne, desinfectante, detergente, frij...
4	[lenteja]	[huevo, pollo]	[agua]	[]	[cerveza, queso, salsa]	[ambientador, blanqueador, cera, desinfectante...	[crema, enjuagar, jabon tocador, proteccion, s...	[aceite, blanqueador, cerveza, desinfectante, ...

Asi mismo, es possible evidenciar todos los ajustes que se le realize a cada uno de los productos originales. Se puede evidenciar la normlaizcion de valores plurals, similares o incoherentes.

Ilustración 14. Lista de comparacion de productos originales a normalizados. Fuente propia.

```python
# Propósito: presentar evidencia de normalización para auditoría y trazabilidad del preprocesamiento.
df_comparison = pd.DataFrame(comparison_rows)
df_comparison = df_comparison.drop_duplicates()

display(df_comparison.head(50))
```

	original	normalized
0	pastas	pasta
1	lentejas	lenteja
2	frijoles	frijol
7	harinas	harina
11	arroz	arroz
14	garbanzos	garbanzo
564	atun	atun
565	pescados	pescado
566	pollo	pollo
567	carne de res	carne
568	huevos	huevo
574	carne de cerdo	carne
1027	te	tú
1028	leche	leche
1029	cafe	cafe
1031	gaseosa	gaseós
1034	agua	agua
1035	chocolate	chocolate
1053	jugos	jugo
1474	papas fritas	papas
1475	dulces	dulce
1476	galletas	galleta
1479	panela	panelar
1487	cereales	cereal
1504	helado	helado
1583	ponque	poncar
1717	salsas	salsa
1718	jamon	jamon

3.3. Codificacion One-Hot (Binarizacion)

Finalizada la normalizacion de los productos, se realiza la binarizacion de cada uno de los productos en las filas de productos. De tal forma que cada uno de los productos quede interpretado como columna, y en cada uno donde se evidencia su compra, se asigne el valor de 1, de lo contrario de 0. Luego de la normalizacion, se obtuvo un total de 61 productos. Por lo tanto al momento de realizar la binarizacion, se obtiene un dataframe de 61 columnas.

Ilustración 15. Dataframe de codificacion One-Hot (Binarizacion). Fuente propia

2.2. Codificación One-Hot

Finalizada la normalizacion de los productos, se realiza la binarizacion de cada uno de los productos en las filas combinadas. De tal forma que cada uno de los productos quede inter
cada uno donde se evidencia su compra, se asigne el valor de 1, de lo contrario de 0

```
# Propósito: generar codificación one-hot de productos para obtener una matriz transaccional binaria.
mlb = MultiLabelBinarizer()
one_hot_array = mlb.fit_transform(combined)
df_one_hot = pd.DataFrame(one_hot_array, columns=mlb.classes_, index=df.index)
PRODUCT_COLUMNS = list(df_one_hot.columns)

df_one_hot.head(10)
```

✓ 0.0s

	aceite	acondicionador	agua	ambientador	arroz	atun	azucar	blanqueador	cafe	carne	...	sal	salchicha	salsa	servilleta	shampoo	suavizante	talco	tú	verdura	vino
0	0	0	0	0	0	1	0	1	0	0	...	0	0	0	0	0	1	1	1	0	0
1	0	1	0	0	0	0	0	1	1	1	...	0	0	1	0	1	0	1	0	0	0
2	0	1	0	0	1	1	0	1	0	1	...	0	0	0	1	0	1	0	0	0	0
3	0	0	0	0	1	0	0	1	1	1	...	0	0	1	1	0	0	0	0	0	0
4	1	0	1	1	0	0	0	1	0	0	...	0	0	1	0	1	1	0	0	0	0
5	0	0	0	0	1	0	0	1	1	1	...	0	1	1	1	0	0	0	0	0	0
6	0	0	1	0	0	1	0	0	1	1	...	0	0	1	1	0	1	1	0	0	0
7	0	0	0	0	1	1	0	1	1	1	...	0	0	0	0	1	1	0	0	0	0
8	0	0	1	0	1	1	1	0	0	1	...	0	1	1	1	1	1	1	1	0	0
9	0	1	0	0	1	0	0	1	1	1	...	0	0	0	0	1	1	0	0	0	0

10 rows × 61 columns

Que al adicionar al dataframe original (Con datos demograficos), se obtiene el archivo completo con un total de 73 columnas.

Ilustración 16. Dataframe completo con productos binarizados. Fuente propia.

Finalmente al dataframe original, se eliminan las columnas con la informacion no procesada, y se le adicionan las columnas de productos binarizados. Lo que representa el dataframe con la estructura completa y lista para realizar el proceso de ECLAT

```
# Propósito: separar base demográfica y unirla con la matriz one-hot para análisis integrado.
df_base = df.drop(columnsrows_to_cols)
df_final = pd.concat([df_base, df_one_hot], axis=1)
df_final.head()
```

✓ 0.2s Python

	fecha	edad	genero	estrato_nse	ciudad_origen	quien_vive	num_personas	quien_compra	mision_compra	canal_compra	...	sal	salchicha	salsa	servilleta	shampoo	suavizante	talco	tú	verdur
0	2026-04-01 08:00:00	18	Masculino	E2	Bogotá	Padres	5	Otra persona	Quincenal	Supermercado (Exito, Jumbo, Etc)	...	0	0	0	0	0	1	1	1	
1	2026-04-01 13:42:00	21	Femenino	E3	Medellín	Padres	4	Otra persona	Mensual	Hard Discount (D1, ARA, etc)	...	0	0	1	0	1	0	1	0	
2	2026-04-01 14:54:00	20	Masculino	E3	Santa Marta	Padres	2	Compartido	Quincenal	Tienda de Barrio	...	0	0	0	1	0	1	0	0	
3	2026-04-01 15:21:00	25	Masculino	E3	Medellín	Familia	6	Compartido	Mensual	Supermercado (Exito, Jumbo, Etc)	...	0	0	1	1	0	0	0	0	
4	2026-04-01 21:55:00	21	Masculino	E3	Bogotá	Familia	4	Yo	Mensual	Supermercado (Exito, Jumbo, Etc)	...	0	0	1	0	1	1	0	0	

5 rows × 73 columns

Es posible visualizar el archivo procesado con todos los productos binarizados a través del siguiente enlace.

Arias S. (2026). Dataframe procesado con productos binarizados.

https://1drv.ms/x/c/9cd239359a0de8d6/IQA_uA8Kuap3To9qK_n6SeN0AeuRa1XnLmLOFBfmd1gTHRo?e=jqNEEQ

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W
1	fecha	edad	genero	estrato_n	ciudad_o	quien_viv	num_pers	quien_co	mision_c	canal_cor	gasto	grupo_ed	aceite	acondicic	agua	ambiente	arroz	atun	azucar	blanquea	cafe	carne	cera
2	2026-04-01 08:00:00	18	Masculin	E2	Bogotá	Padres	5	Otra pers	Quincena	Supermer	700000	Menor de	0	0	0	0	0	1	0	1	0	0	0
3	2026-04-01 13:42:00	21	Femenin	E3	Medellín	Padres	4	Otra pers	Mensual	Hard Disc	1000000	18-25	0	1	0	0	0	0	0	1	1	1	0
4	2026-04-01 14:54:00	20	Masculin	E3	Santa Ma	Padres	2	Compartic	Quincena	Tienda de	500000	18-25	0	1	0	0	1	1	0	1	0	1	1
5	2026-04-01 15:21:00	25	Masculin	E3	Medellín	Familia	6	Compartic	Mensual	Supermer	2000000	18-25	0	0	0	0	1	0	0	1	1	1	1
6	2026-04-01 21:55:00	21	Masculin	E3	Bogotá	Familia	4	Yo	Mensual	Supermer	1200000	18-25	1	0	1	1	0	0	0	1	0	0	1
7	2026-04-02 07:15:00	24	Masculin	E3	Bogotá	Padres	5	Otra pers	Mensual	Hard Disc	1200000	18-25	0	0	0	0	1	0	0	1	1	1	1
8	2026-04-02 09:24:00	23	Masculin	E3	Cali	Padres	5	Compartic	Quincena	Supermer	1500000	18-25	0	0	1	0	0	1	0	0	1	1	0
9	2026-04-02 10:50:00	18	Femenin	E3	Bogotá	Familia	2	Yo	Diario	Tienda de	1200000	Menor de	0	0	0	0	1	1	0	1	1	1	0
10	2026-04-02 17:22:00	25	Femenin	E3	Cali	Padres	3	Yo	Mensual	Supermer	1200000	18-25	0	0	1	0	1	1	0	0	0	1	0
11	2026-04-02 18:29:00	25	Femenin	E3	Bogotá	Familia	6	Compartic	Quincena	Plaza de l	1500000	18-25	0	1	0	0	1	0	0	1	1	1	0
12	2026-04-03 07:47:00	19	Masculin	E3	Bogota D.	Padres	4	Otra pers	Mensual	Supermer	700000	18-25	0	0	0	0	0	0	0	0	0	1	0
13	2026-04-03 12:41:00	21	Masculin	E2	Bogotá	Familia	3	Otra pers	Quincena	Supermercado (Exit		18-25	0	0	0	0	0	0	0	1	1	1	1
14	2026-04-03 13:40:00	19	Masculin	E3	Bogota	Padres	2	Otra pers	Semanal	Hard Disc	700000	18-25	0	0	0	0	1	1	0	1	1	1	0
15	2026-04-03 18:57:00	18	Masculin	E4	Bogotá D.	Familia	5	Compartic	Quincena	Supermer	1000000	Menor de	0	0	1	0	0	0	0	0	0	1	1
16	2026-04-03 22:48:00	22	Masculin	E3	Bogota	Padres	3	Otra pers	Quincena	Tienda de	500000	18-25	0	0	0	0	1	0	0	1	1	0	0
17	2026-04-04 07:05:00	40	Masculin	E3	Bogota	Familia	4	Compartic	Mensual	Supermer	1200000	31-60	0	1	0	0	0	1	0	1	1	1	0
18	2026-04-04 09:11:00	24	Masculin	E4	Santa Ma	Padres	5	Compartic	Semanal	Supermer	2000000	18-25	0	1	1	1	1	0	0	1	1	1	0
19	2026-04-04 11:25:00	21	Masculin	E2	mani casa	Familia	4	Otra pers	Quincena	Hard Disc	500000	18-25	0	1	1	0	1	0	1	0	1	0	1
20	2026-04-04 15:58:00	19	Masculin	E3	Bogota	Padres	7	Compartic	Quincena	Hard Disc	1000000	18-25	0	0	0	0	1	0	0	1	1	1	0
21	2026-04-04 21:21:00	19	Masculin	E3	Bogota	Padres	8	Compartic	Mensual	Tienda de Barrio		18-25	1	0	1	0	1	1	0	0	1	1	0
22	2026-04-04 21:49:00	25	Masculin	E1	Cartagena	Familia	5	Compartic	Quincena	Supermer	1200000	18-25	0	0	1	0	0	0	0	1	1	1	0
23	2026-04-05 07:12:00	25	Masculin	E3	Bogota	Familia	4	Otra pers	Mensual	Hard Disc	600000	18-25	0	1	0	0	1	0	0	0	1	1	1
24	2026-04-05 13:33:00	21	Masculin	E2	Bogota	Padres	4	Otra pers	Semanal	Hard Discount (D1,		18-25	0	0	1	1	1	0	0	0	1	1	0
25	2026-04-05 19:20:00	22	Masculin	E4	Bogotá	Familia	6	Compartic	Quincena	Hard Disc	1200000	18-25	0	0	0	0	0	1	0	1	1	1	0
26	2026-04-06 07:34:00	19	Masculin	E3	Bogota	Padres	2	Compartic	Semanal	Hard Disc	1200000	18-25	0	0	0	0	0	0	0	0	0	0	0
27	2026-04-06 11:23:00	21	Masculin	E4	Bogotá	Familia	2	Compartic	Semanal	Tienda de	600000	18-25	0	0	1	0	1	0	0	0	1	0	0
28	2026-04-06 13:30:00	22	Masculin	E3	Medellín	Padres	4	Compartic	Quincena	Supermer	1700000	18-25	0	0	0	0	1	0	0	0	1	1	0
29	2026-04-06 17:34:00	22	Femenin	E4	Bogota	Padres	4	Otra pers	Quincena	Supermer	1000000	18-25	0	0	0	0	1	0	0	1	0	1	0
30	2026-04-06 22:50:00	18	Masculin	E4	Bogota	Familia	4	Yo	Diario	Supermer	1800000	Menor de	0	0	1	0	1	1	0	1	0	1	0
31	2026-04-07 07:51:00	23	Masculin	E3	Bogotá	Familia	2	Compartic	Mensual	Hard Disc	400000	18-25	0	0	0	0	1	0	0	1	0	1	0
32	2026-04-07 08:09:00	19	Masculin	E4	Bogotá	Padres	3	Otra pers	Semanal	Hard Disc	700000	18-25	0	0	0	0	0	1	0	1	0	1	0
33	2026-04-07 14:52:00	21	Femenin	E4	Bogotá	Padres	6	Otra pers	Mensual	Hard Disc	1000000	18-25	0	0	0	1	0	1	0	1	0	1	0
34	2026-04-07 16:28:00	18	Femenin	E4	Bogotá	Familia	4	Otra pers	Mensual	Supermer	1200000	Menor de	0	0	0	0	1	1	0	1	1	1	0

3.4. Análisis Exploratorio (frecuencias)

Al realizar el analisis exploratorio de frecuencias de todos los productos encontrados, es posible identificar que el producto mas repetivo en toda la muestra, es el producto de carne con un total de 148 frecuencias. Seguido de la crema con 127 y posteriormente el arroz con 113 apariciones.

Ilustración 17. Analisis exploratorio de frecuencias. Fuente propia

2.3. Análisis Exploratorio (frecuencias)

Aquí usamos la matriz one-hot como única fuente de productos para garantizar consistencia analítica, donde se identifican los productos mas frecuentes junto al soporte para la exploracion inicial.

Se identifica que la carne es el producto mas frecuente con un total de 148 presencias en todo el dataframe

```python
# Propósito: identificar productos más frecuentes y su soporte para contexto exploratorio inicial.
cols_productos = PRODUCT_COLUMNS

productos_df = df_final[cols_productos]
freq_productos = productos_df.sum(numeric_only=True)

freq_productos_df = pd.DataFrame(

    {"producto": cols_productos, "frecuencia": freq_productos}
).sort_values(by="frecuencia", ascending=False)

freq_productos_df.head(20)
```

[37] ✓ 0.1s Python

	producto	frecuencia
carne	carne	148
crema	crema	127
arroz	arroz	113
frijol	frijol	113
pollo	pollo	110
pasta	pasta	107
harina	harina	106
lenteja	lenteja	105
leche	leche	102
cafe	cafe	101
detergente	detergente	99
blanqueador	blanqueador	94
papel	papel	93
shampoo	shampoo	87
chocolate	chocolate	86
jabon tocador	jabon tocador	85

A los cuales tranformamos a formato transaccional adicionando el calculo del soporte de cada uno de los productos. Donde se evidenciaron un total de 200 transacciones con un total de 61 productos.

Ilustración 18. Transformacion a formato transaccional y calculo de soporte. Fuente Propia.

```
# Propósito: convertir frecuencias a soporte para interpretar ocurrencia relativa de cada producto.
support_productos = (freq_productos / len(productos_df)).round(4)

resumen_frecuencia = pd.DataFrame(
    {
        'frecuencia': freq_productos,
        'support': support_productos,
    }
).sort_values('support', ascending=False)

print('Productos detectados:', len(cols_productos))
print('Transacciones:', len(productos_df))
display(resumen_frecuencia.head(20))
```

[18] ✓ 0.2s

```
Productos detectados: 61
Transacciones: 200
```

	frecuencia	support
carne	148	0.740
crema	127	0.635
arroz	113	0.565
frijol	113	0.565
pollo	110	0.550
pasta	107	0.535
harina	106	0.530
lenteja	105	0.525
leche	102	0.510
cafe	101	0.505
detergente	99	0.495
blanqueador	94	0.470
papel	93	0.465
shampoo	87	0.435
chocolate	86	0.430
jabon tocador	85	0.425
huevo	85	0.425
suavizante	81	0.405
lavalozar	80	0.400
servilleta	79	0.395

Gracias a estos datos, se puede evidenciar una concentración muy fuerte en productos básicos. Ya que debido a que el producto de carne tenga unsoporte de 0.74 significa que aparece en el 74% de las transacciones. Por lo tanto no es un producto más sino un estándar del hogar.

Lo mismo ocurre con arroz, frijol, pollo, pasta y harina debido a que todos se encuentran por encima del 50%, lo que indica que forman parte de una canasta básica familiar.

Las compras están altamente concentradas en un conjunto reducido de productos esenciales, con muy poca dispersión, lo que implica que los patrones de consumo son estables, repetitivos y altamente predecibles.

Capitulo 4. Implementación del modelo

En esta parte del proyecto se aplica el algoritmo ECLAT sobre la matriz construida en el preprocesamiento. Aquí se define con claridad cómo se calcula el soporte de los itemsets y cuáles son los parámetros que controlan la búsqueda de patrones frecuentes.

4.1. Definición de los parámetros.

Se realiza la definición de los parámetros de soporte mínimo y del numero máximo de ítems por cada set.

Tabla 2. Tabla de parametros del modelo. Fuente propia

Parametro	**Valor**
MIN_SUPPORT	0.3
MAX_ITEMSET	3

4.2. Aplicación de ECLAT.

Se realiza la definición del modelo ECLAT con un objetivo de descubrir qué productos se compran juntos de forma frecuente, basándose en los datos ya limpios y estructurados.

Para la aplicación del modelo ECLAT, se utilizan principalmente dos funciones dadas por build_transactions y run_eclat.

4.2.1. Función build_transactions.

Inicialmente, la función build_transactions toma la matriz binaria estandarizada anteriormente y la convierte en una lista de transacciones. Es decir, transforma cada fila en una lista de productos que sí fueron comprados. De modo que los productos se representan en listas.

Ilustración 19. Transacciones creadas por los productos estandarizados. Fuente propia

3.2 Ejecución del modelo ECLAT

En esta sección se ejecuta el modelo sobre los datos procesados y se consolida la tabla `freq_df`, que contiene los itemsets frecuentes con su soporte. Este resultado es la base para construir reglas de asociación en la fase siguiente.

```python
# Propósito: ejecutar el algoritmo ECLAT sobre la base final y obtener itemsets frecuentes.
MIN_SUPPORT = 0.3
MAX_ITEMSET = 3

freq_df, support_cache, productos_df = run_eclat(df_final, MIN_SUPPORT, MAX_ITEMSET)
print("Itemsets frecuentes:", len(freq_df))
display(freq_df)
```

✓ 3.4s Python

```
[['atun', 'blanqueador', 'colonia', 'desinfectante', 'lavalozar', 'leche', 'lenteja', 'loción', 'papel', 'pasta', 'suavizante', 'talco', 'tú'], ['acondicionador', 'blanqueador', 'cafe', 'carne', 'fr
Itemsets frecuentes: 80
```

Ilustración 20. Funcion build_transactions. Fuente propia

```python
# Propósito: implementar ECLAT reusable con estructura vertical y cache de soporte.
def build_transactions(product_binary_df: pd.DataFrame) -> list[list[str]]:
    """Convierte matriz binaria de productos a lista de transacciones."""
    return [
        list(product_binary_df.columns[row.values == 1])
        for _, row in product_binary_df.iterrows()
    ]
```

4.2.2. Función run_eclat.

En la función run_eclat, comienza el proceso principal. Lo primero que hace es quedarse únicamente con las columnas de productos y asegurar que todos los valores estén en formato binario. Con esto construye las transacciones y calcula cuántas hay en total, lo cual es clave para medir la frecuencia relativa o el soporte ya visto anteriormente (support).

Ilustración 21. Construccion de transacciones y calculo de sporte en la funcion run_eclat. Fuente propia

```python
def run_eclat(
    data: pd.DataFrame,
    min_support: float,
    max_len: int,
) -> tuple[pd.DataFrame, dict[frozenset[str], float], pd.DataFrame]:
    """Ejecuta ECLAT y retorna itemsets frecuentes, cache de soporte y dataframe de productos."""
    product_cols = [c for c in PRODUCT_COLUMNS if c in data.columns]
    data_products = data[product_cols].fillna(0).astype(int)
    transactions = build_transactions(data_products)

    print(transactions)

    n = len(transactions)
    if n == 0:
        return pd.DataFrame(columns=["itemset", "support"]), {}, data_products

    tid_lists: dict[str, set[int]] = {}
    for tid, trans in enumerate(transactions):
        for item in trans:
            tid_lists.setdefault(item, set()).add(tid)

    support_cache: dict[frozenset[str], float] = {}
    frequent_itemsets: list[dict[str, object]] = []
    items = sorted(tid_lists.keys())
```

En lugar de recorrer las transacciones una y otra vez, el algoritmo reorganiza la información creando un índice, donde para cada producto, guarda en qué transacciones aparece. Esto permite que, cuando quiera saber si dos o más productos aparecen juntos, simplemente cruce esos registros, sin tener que revisar toda la base nuevamente.

Ilustración 22. Creacion de los itemsets del eclat a traves de indices. Fuente propia

```
for size in range(1, max_len + 1):
    for combo in combinations(items, size):
        tids = tid_lists[combo[0]].copy()
        for item in combo[1:]:
            tids &= tid_lists[item]
            if not tids:
                break

        if not tids:
            continue

        support = len(tids) / n
        if support >= min_support:
            key = frozenset(combo)
            support_cache[key] = support
            frequent_itemsets.append({"itemset": key, "support": round(support, 4)})

if not frequent_itemsets:
    return pd.DataFrame(columns=["itemset", "support"]), support_cache, data_products

freq_df = (
    pd.DataFrame(frequent_itemsets)
    .sort_values(["support", "itemset"], ascending=[False, True])
    .reset_index(drop=True)
)
return freq_df, support_cache, data_products
```

A partir de ahí, el algoritmo empieza a generar combinaciones de productos de tamaño 1 hasta el máximo definido (Máximo 3 dado por el parámetro MAX_ITEMSET), donde para cada combinación, calcula en cuántas transacciones aparece en conjunto. Si esa frecuencia supera el umbral mínimo de 0.3 (30%) dado por el parámetro MIN_SUPPORT, entonces esa combinación se considera relevante y se guarda.

De tal forma que todo el flujo toma compras individuales y responde a la pregunta de ¿Qué productos tienden a aparecer juntos de forma consistente en las compras?

Ilustración 23. Primeros 20 conjuntos de itemset creados a traves de la implementacion del ECLAT. Fuente propia

	itemset	support
0	frozenset({carne})	0.740
1	frozenset({crema})	0.635
2	frozenset({arroz})	0.565
3	frozenset({frijol})	0.565
4	frozenset({pollo})	0.550
5	frozenset({pasta})	0.535
6	frozenset({harina})	0.530
7	frozenset({lenteja})	0.525
8	frozenset({leche})	0.510
9	frozenset({cafe})	0.505
10	frozenset({detergente})	0.495
11	frozenset({carne, crema})	0.490
12	frozenset({blanqueador})	0.470
13	frozenset({papel})	0.465
14	frozenset({frijol, carne})	0.440
15	frozenset({arroz, carne})	0.440
16	frozenset({shampoo})	0.435
17	frozenset({chocolate})	0.430
18	frozenset({jabon tocador})	0.425
19	frozenset({huevo})	0.425

Y con los parámetros definidos (soporte mínimo del 30% y máximo 3 productos por combinación), se enfoca únicamente en patrones realmente fuertes y representativos del comportamiento general, no en coincidencias aisladas.

Capitulo 5. Resultados

Para la parte de los resultados se transforman los itemsets frecuentes en reglas de asociación y se calculan sus métricas principales. De tal forma que se pueda identificar relaciones relevantes entre productos y reportarlas con soporte, confianza y lift para la lectura clara de los hallazgos.

5.1. Reglas de asociación.

Para las reglas de asociación se utilizaron las siguientes métricas de asociación.

Ilustración 24. Metricas utilizadas en las reglas de asociacion encontradas. Fuente propia

Reglas	
support	Soporte Proporción de transacciones en las que aparece un producto o conjunto de productos
confidence	Confianza Probabilidad de que ocurra un producto dado que otro ya ocurrió
lift	Elevación Qué tanto más probable es que dos productos aparezcan juntos frente a si fueran independientes
affinity	Afinidad Grado de relación o asociación entre productos, generalmente usado como medida interpretativa de cercanía
score	Puntuación Valor agregado que combina métricas para priorizar o rankear reglas según su relevancia

De los cuales se obtuvieron las siguientes métricas. Es este caso se observa que el hallazgo más fuerte es que la carne es el eje central de casi todas las reglas. Aparece como producto consecuente en la mayoría de las reglas más relevantes. Esto significa que muchos otros productos conducen a la compra de carne.

Por ejemplo, cuando alguien compra café, pasta, frijol o arroz, hay una probabilidad cercana al 78% de que también compre carne.

Ilustración 25. Reglas relevantes de acuerdo a las metricas utilizadas. Fuente propia

```
Reglas generadas: 76
Top 5 reglas relevantes (soporte, confianza y lift):
```

	antecedent	consequent	support	confidence	lift	affinity	score
0	cafe	carne	0.405	0.8020	1.0838	0.8692	0.7277
1	pasta	carne	0.420	0.7850	1.0609	0.8328	0.7218
2	frijol	carne	0.440	0.7788	1.0524	0.8196	0.7253
3	arroz	carne	0.440	0.7788	1.0524	0.8196	0.7253
4	lavalozar	carne	0.310	0.7750	1.0473	0.8117	0.6707
...	...	...	...	...	...	...	...
71	carne	chocolate	0.330	0.4459	1.0371	0.4625	0.5769
72	carne	huevo	0.320	0.4324	1.0175	0.4400	0.5630
73	carne	lavalozar	0.310	0.4189	1.0473	0.4387	0.5639
74	carne	servilleta	0.300	0.4054	1.0263	0.4161	0.5495
75	carne	suavizante	0.300	0.4054	1.0010	0.4058	0.5419

76 rows × 7 columns

Y se puede observar que las confianzas son altas en algunos casos, lo que indica que estas combinaciones no son débiles ni ocasionales. A pesar de todo, el lift está apenas por encima de 1 en la mayoría de los casos, lo que es clave interpretarlo correctamente.

Los productos sí aparecen juntos, pero más por hábito general de compra que por una dependencia fuerte entre ellos. Es decir, no es que "comprar café cause comprar carne", sino que ambos hacen parte de una misma rutina de abastecimiento.

Tabla 3. Reglas relevantes por afinidad y por puntaje. Fuente propia

Top 10 por affinity

	antecedent	consequent	support	confidence	lift	affinity	score
0	cafe	carne	0.405	0.8020	1.0838	0.8692	0.7277
1	pasta	carne	0.420	0.7850	1.0609	0.8328	0.7218
2	frijol	carne	0.440	0.7788	1.0524	0.8196	0.7253
3	arroz	carne	0.440	0.7788	1.0524	0.8196	0.7253
4	lavalozar	carne	0.310	0.7750	1.0473	0.8117	0.6707
...	...	...	...	...	...	...	...
71	carne	chocolate	0.330	0.4459	1.0371	0.4625	0.5769
72	carne	huevo	0.320	0.4324	1.0175	0.4400	0.5630
73	carne	lavalozar	0.310	0.4189	1.0473	0.4387	0.5639
74	carne	servilleta	0.300	0.4054	1.0263	0.4161	0.5495
75	carne	suavizante	0.300	0.4054	1.0010	0.4058	0.5419

76 rows × 7 columns

Top 10 por score

	antecedent	consequent	support	confidence	lift	affinity	score
5	crema	carne	0.490	0.7717	1.0428	0.8047	0.7403
0	cafe	carne	0.405	0.8020	1.0838	0.8692	0.7277
3	arroz	carne	0.440	0.7788	1.0524	0.8196	0.7253
2	frijol	carne	0.440	0.7788	1.0524	0.8196	0.7253
1	pasta	carne	0.420	0.7850	1.0609	0.8328	0.7218
...	...	...	...	...	...	...	...
70	crema	papel	0.300	0.4724	1.0160	0.4800	0.5665
73	carne	lavalozar	0.310	0.4189	1.0473	0.4387	0.5639
72	carne	huevo	0.320	0.4324	1.0175	0.4400	0.5630
74	carne	servilleta	0.300	0.4054	1.0263	0.4161	0.5495
75	carne	suavizante	0.300	0.4054	1.0010	0.4058	0.5419

76 rows × 7 columns

El comportamiento de compra gira alrededor de una canasta base donde la carne actúa como producto central, y el resto de productos orbitan alrededor de esa decisión principal de compra.

5.1.1. ECLAT — Reglas de Asociación

Visualizando las reglas en un plano de soporte y confianza, se puede evidenciar que el tamaño se encuentra definido por el lift. Por lo tanto se puede identificar con rapidez qué reglas tienen buen equilibrio entre frecuencia y fuerza de asociación.

Tabla 4. Reglas relevantes por afinidad y por puntaje. Fuente propia

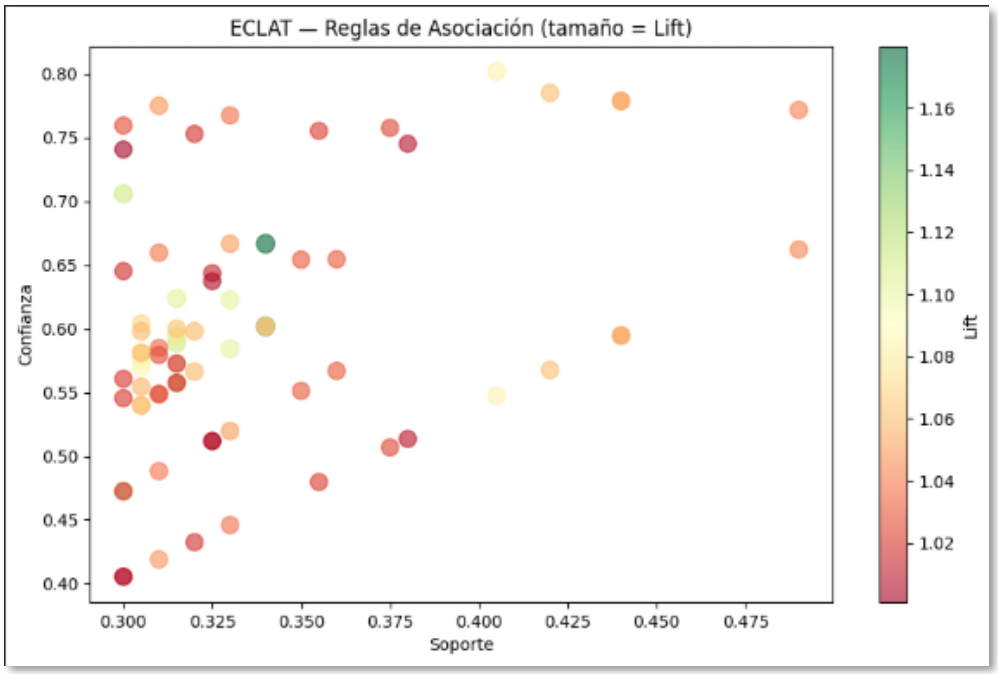

5.1.2. Heatmap de Lift

Y con los valores del lift de las reglas más relevantes se construye el mapa de calor que permite reconocer de forma directa qué combinaciones presentan relaciones más fuertes entre antecedente y consecuente.

Ilustración 26. Heatmap de lift de lascombinaciones mas fuertes. Fuente propia

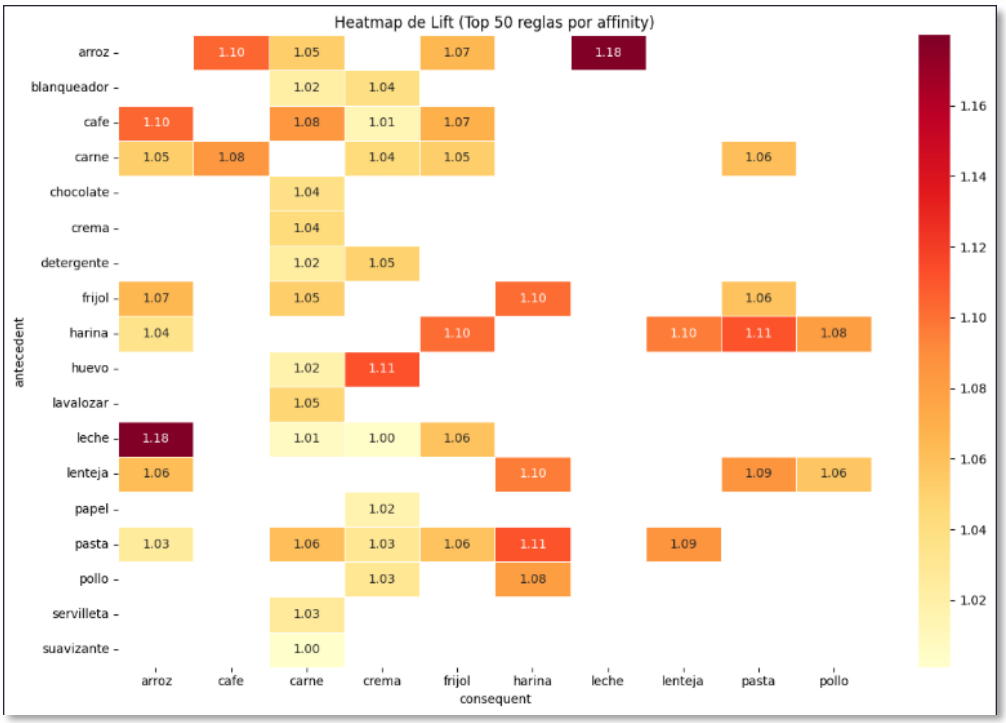

5.1.3. Red de afinidad

Asi mismo, se puede representar la red de afinidad entre productos, donde el peso de las conexiones está asociado al lift, de esta forma es posible comprender la estructura global de las asociaciones dentro de la canasta de compra. Se puede evidenciar claramente como la carne se ve representado como el productop con mayor cantidad de conexiones.

Ilustración 27. Red de afinidad de las reglas de asociacion. Fuente propia

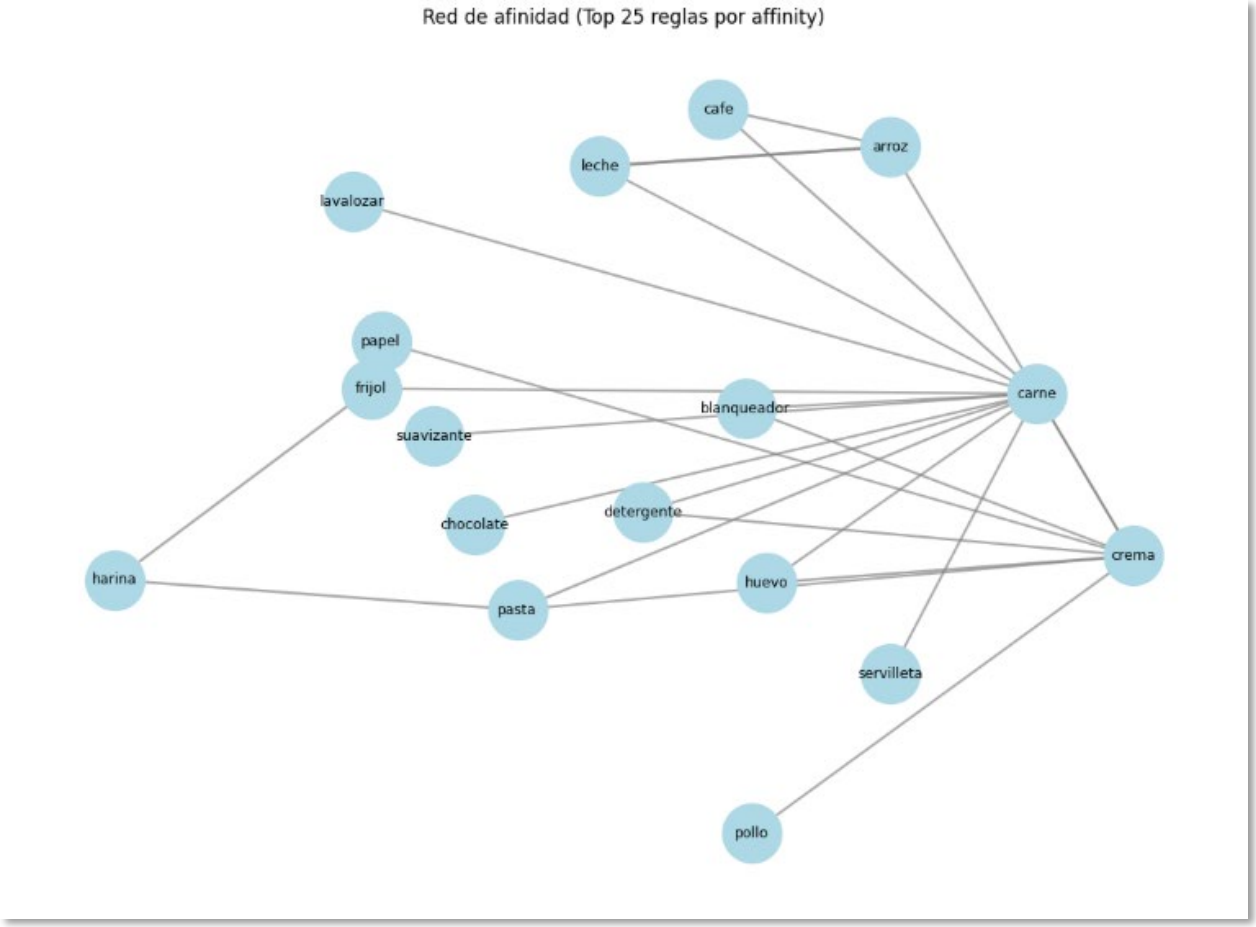

5.1.4. Distribucion de métricas de reglas ECLAT.

Al realizar el análisis de la distribución de soporte, confianza y lift para evaluar la calidad global de las reglas, se puede detectar si los resultados están concentrados en pocas reglas o si existe una estructura más equilibrada.

La distribución muestra que la mayoría de las reglas tienen un support cercano al mínimo (entre 0.30 y 0.35), lo que indica que son patrones frecuentes pero no dominantes en toda la población. El confidence se concentra entre 0.55 y 0.65, con algunos valores más altos, lo que sugiere que las reglas tienen una capacidad predictiva moderada indicando que son consistentes, pero no determinan completamente el comportamiento.

Ilustración 28. Distribucion de métricas de las reglas ECLAT. Fuente propia

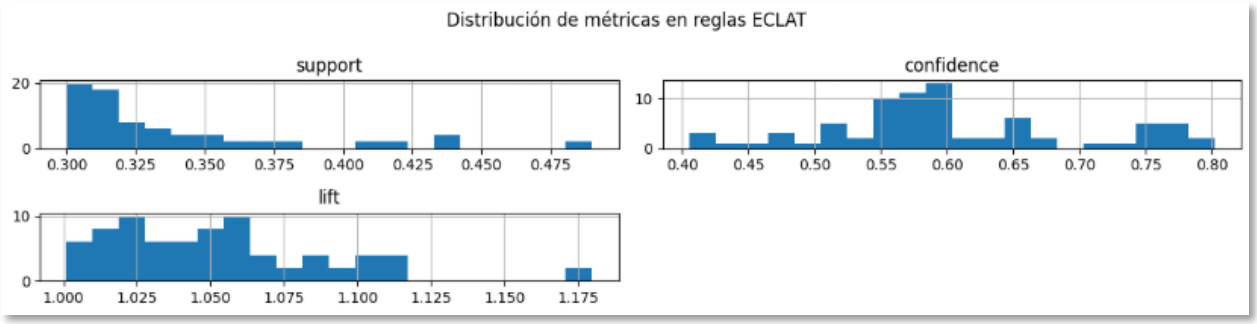

Por otro lado, el lift está muy cercano a 1, lo que revela que las asociaciones no son fuertes en términos de dependencia, sino que los productos simplemente tienden a aparecer juntos dentro de una misma compra. En conjunto, esto refleja un comportamiento de consumo estable y repetitivo, basado en una canasta básica, más que en relaciones específicas o inesperadas entre productos.

Capitulo 6. Intepretacion

Intepretando los resultados desde una perspectiva aplicada se puede comparar los comportamientos de compra por estrato y por el grupo de edad calculado con el fin de traducirlo en decisiones de negocio.

6.1. Lecuta por estrato socioeconómico.

6.1.1. Estrato 1.

Al realizar una búsqueda de las reglas de asociación presentes para los estrados 1, se puede evidenciar que los datos son muy pocos, pero ya se ve un patrón básico donde carne y la harina dominan, acompañados por productos de aseo y consumo general. Las combinaciones sugieren compras de alimentos y aseo en una sola salida, pero la muestra es tan pequeña que solo da algunos indicios.

Ilustración 29. Distribucion de reglas para el estrato 1. Fuente propia

Estrato E1 | registros: 7

	itemset	support
0	frozenset({carne})	0.7143
1	frozenset({harina})	0.7143
2	frozenset({acondicionador})	0.5714
3	frozenset({harina, lavalozar, carne})	0.5714
4	frozenset({gaseós, frijol, pasta})	0.5714
5	frozenset({pasta})	0.5714
6	frozenset({perfumir})	0.5714
7	frozenset({lavalozar})	0.5714
8	frozenset({papel})	0.5714
9	frozenset({agua})	0.5714

6.1.2. Estrato 2.

Para el estrado 2, aparece una canasta más estructurada y estable, donde carne sigue siendo central, acompañada de crema, arroz, pollo y leche. Aquí ya se evidencia un patrón claro de alimentación completa y balanceada, junto con productos de aseo, lo que indica compras más organizadas y recurrentes.

Ilustración 30. Distribucion de reglas para el estrato 2. Fuente propia

Estrato E2 | registros: 50

	itemset	support
0	frozenset({carne})	0.72
1	frozenset({crema})	0.62
2	frozenset({arroz})	0.58
3	frozenset({pollo})	0.58
4	frozenset({leche})	0.54
5	frozenset({detergente})	0.50
6	frozenset({pasta})	0.50
7	frozenset({agua})	0.48
8	frozenset({acondicionador})	0.46
9	frozenset({carne, crema})	0.46

6.1.3. Estrato 3.

Para el estrato 3, se evidencia el comportamiento más consistente y representativo, ya que hay una canasta alimentaria muy definida (carne, crema, frijol, arroz, café, lenteja), con alta frecuencia en todos los productos. Esto refleja hábitos de consumo muy estables, donde las compras están bien estructuradas y cubren necesidades completas del hogar.

Ilustración 31. Distribucion de reglas para el estrato 3. Fuente propia

Estrato E3 | registros: 95

	itemset	support
0	frozenset({carne})	0.7368
1	frozenset({crema})	0.6842
2	frozenset({frijol})	0.5895
3	frozenset({cafe})	0.5895
4	frozenset({harina})	0.5895
5	frozenset({arroz})	0.5895
6	frozenset({lenteja})	0.5684
7	frozenset({pollo})	0.5684
8	frozenset({pasta})	0.5474
9	frozenset({carne, crema})	0.5368

6.1.4. Estrato 4.

Para el estrato 4, se mantiene la base alimentaria fuerte (carne, frijol, arroz), pero se nota mayor presencia de productos complementarios como chocolate y blanqueador. Esto sugiere una canasta más diversificada, donde además de lo básico, empiezan a aparecer productos adicionales que amplían el consumo más allá de lo esencial.

Ilustración 32. Distribucion de reglas para el estrato 4. Fuente propia

Estrato E4 | registros: 48

	itemset	support
0	frozenset({carne})	0.7708
1	frozenset({frijol})	0.6875
2	frozenset({blanqueador})	0.6250
3	frozenset({crema})	0.5833
4	frozenset({frijol, carne})	0.5625
5	frozenset({lenteja})	0.5417
6	frozenset({chocolate})	0.5417
7	frozenset({pasta})	0.5417
8	frozenset({arroz})	0.5208
9	frozenset({pollo})	0.5208

6.1.5. Soporte por producto y estrato socioeconómico

Al realizar un analisis de la grafica, se evidencia que la carne es el producto más consistente en todos los estratos, aumentando ligeramente a medida que sube el nivel socioeconómico. Esto confirma que es el eje central del consumo sin importar el estrato.

Además, productos como arroz, lenteja y pasta se mantienen relativamente estables entre grupos, lo que refuerza la idea de una canasta básica común.

Ilustración 33. Soporte por producto y estrato socioeconomico. Fuente propia

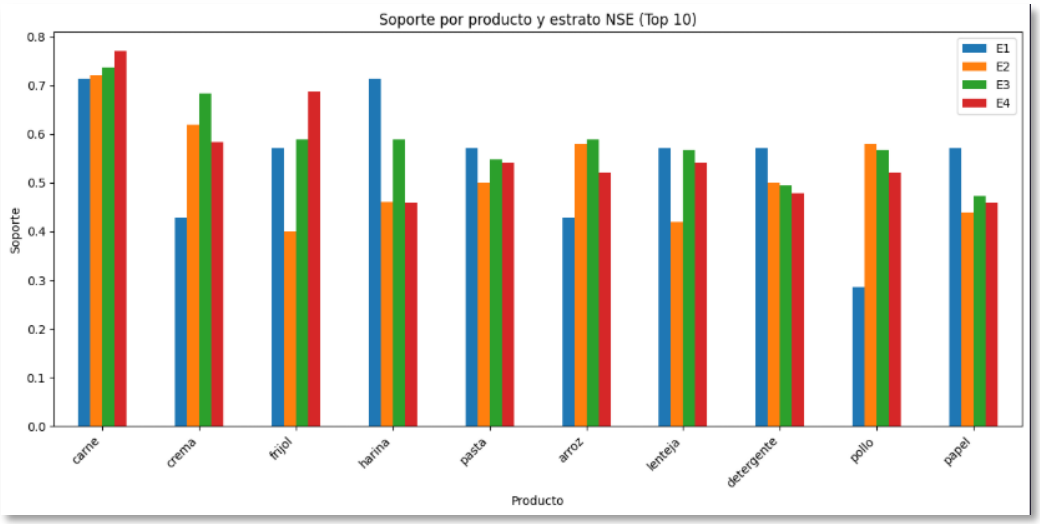

Sin embargo, se observan diferencias claras en otros productos: en estratos más altos (E3 y E4) aumenta el consumo de crema, frijol y pollo, lo que indica una mayor diversificación de la alimentación. En cambio, en estratos más bajos (E1 y E2), productos como harina y papel tienen mayor presencia, reflejando un consumo más enfocado en lo esencial.

6.2. Lectura por grupo de edad.

6.2.1. Grupo 1. Menor de 18 años

Con la lectura por grupos de edad, se puede observar un consumo bastante equilibrado entre alimentos (carne, pollo, frijol) y productos de aseo. La gráfica muestra valores medios-altos en casi todos los productos, lo que indica que este grupo participa en compras completas del hogar, no solo en productos específicos.

Puede estar muy relacionado a encargos por parte de los acudientes de estos niños. Ya que por lo general este grupo de edad, siempre realiza los encargos de compras dichos por sus acudientes.

Ilustración 34. Distribucion de reglas para el grupo de edad Menor a 18. Fuente propia

Grupo Menor de 18 | registros: 20

	itemset	support
0	frozenset({carne})	0.80
1	frozenset({pollo})	0.75
2	frozenset({frijol})	0.70
3	frozenset({pollo, carne})	0.65
4	frozenset({crema})	0.60
5	frozenset({blanqueador})	0.60
6	frozenset({shampoo})	0.60
7	frozenset({frijol, carne})	0.60
8	frozenset({arroz})	0.55
9	frozenset({jabon tocador})	0.55

6.2.2. Grupo 2. 18-25 años

Este grupo es el grupo con mayor volumen de registros y muestra un comportamiento de compra muy estable. La carne vuelve a ser el producto central, seguida por crema, arroz, frijol, harina, pasta, lenteja, pollo y leche. Aquí se ve una canasta muy estructurada, con fuerte presencia de alimentos básicos y una compra recurrente que parece enfocada en abastecimiento completo del hogar.

Ilustración 35. Distribucion de reglas para el grupo de edad entre 18 y 25 años. Fuente propia

Grupo 18-25 | registros: 174

	itemset	support
0	frozenset({carne})	0.7471
1	frozenset({crema})	0.6322
2	frozenset({arroz})	0.5747
3	frozenset({frijol})	0.5575
4	frozenset({harina})	0.5460
5	frozenset({pasta})	0.5345
6	frozenset({lenteja})	0.5287
7	frozenset({pollo})	0.5230
8	frozenset({leche})	0.5115
9	frozenset({carne, crema})	0.5000

6.2.3. Grupo 3. 26-30 años

Para el grupo con un rango de edad de 26 a 30 años, se nota una compra más diversificada y con fuerte presencia de productos de aseo y cuidado personal, como blanqueador, hilo, crema y acondicionador.

También aparecen combinaciones frecuentes entre crema, hilo y otros productos, lo que sugiere una canasta más específica y menos centrada solo en alimentos básicos.

Ilustración 36. Distribucion de reglas para el grupo de edad entre 26 y 30 años. Fuente propia

Grupo 26-30 | registros: 5

	itemset	support
0	frozenset({blanqueador})	0.8
1	frozenset({crema, hilo})	0.8
2	frozenset({hilo})	0.8
3	frozenset({crema})	0.8
4	frozenset({acondicionador})	0.6
5	frozenset({detergente, crema, hilo})	0.6
6	frozenset({pasta, crema, hilo})	0.6
7	frozenset({papel, crema, hilo})	0.6
8	frozenset({lenteja, crema, hilo})	0.6
9	frozenset({blanqueador, crema, hilo})	0.6

6.2.4. Grupo 4. 31-60 años

Finalmente para el grupo de 31 a 60 años, no se permite una lectura sólida porque solo tiene un registro, así que los resultados no representan un patrón general. Lo que aparece refleja únicamente esa compra puntual, donde se mezclan carne, lavalozar, papel, jabón y otros productos de aseo, pero no es válido interpretarlo como comportamiento del grupo completo.

Grupo 31-60 | registros: 1

	itemset	support
0	frozenset({acondicionador})	1.0
1	frozenset({lavalozar, carne, talco})	1.0
2	frozenset({lavalozar, suavizante, carne})	1.0
3	frozenset({pollo, lavalozar, carne})	1.0
4	frozenset({lavalozar, carne, pasta})	1.0
5	frozenset({lavalozar, carne, papel})	1.0
6	frozenset({lenteja, lavalozar, carne})	1.0
7	frozenset({lenteja, carne, papel})	1.0
8	frozenset({jabon tocador, carne, talco})	1.0
9	frozenset({pollo, jabon tocador, carne})	1.0

6.2.5. Soporte por producto y grupo de edad

Para la gráfica del soporte para los grupos de edad se muestra que la carne sigue siendo un producto central en todos los grupos de edad, especialmente en menores de 18 y en el grupo de 18-25. Gran parte de estos productos se pueden interpretar como los encargados por parte de los integrantes mayores de las viviendas de estos grupos de edad.

Ilustración 37. Soporte por producto y grupo de edad. Fuente propia

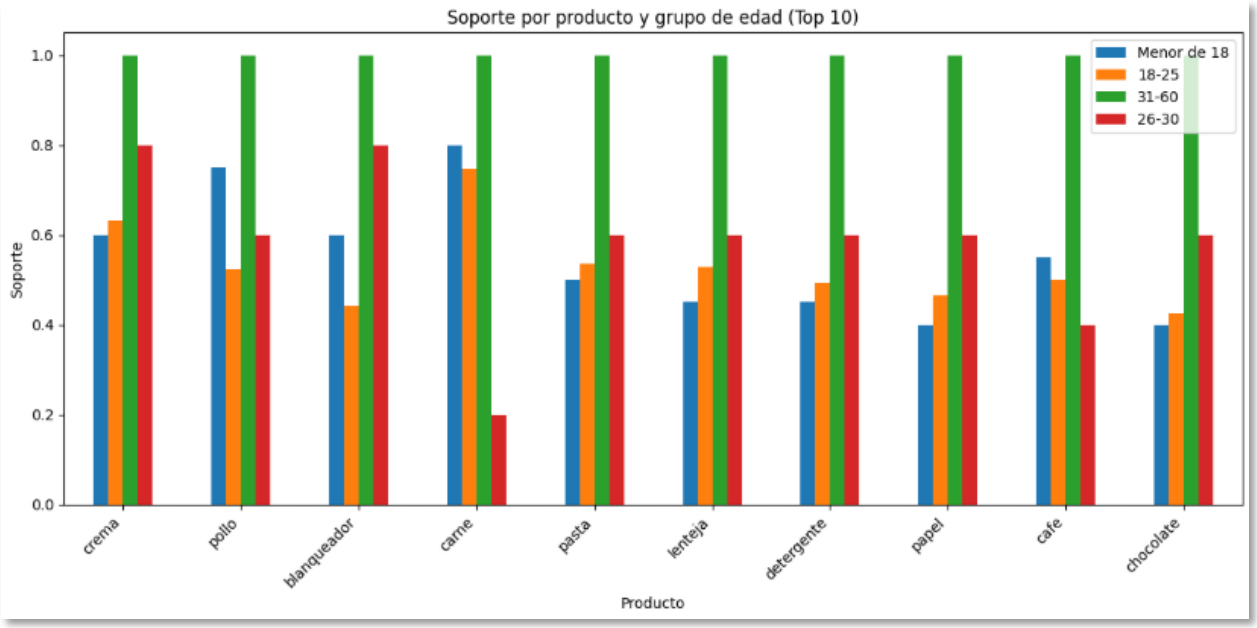

Sin embargo, existen diferencias claras. Por ejemplo en el grupo de 31-60 presenta valores máximos (cercanos a 1) en todos los productos, pero esto no es representativo debido a la baja cantidad de datos.

En cambio, el grupo de 26-30 muestra mayor variabilidad, con menor presencia en productos como carne pero mayor en otros como crema o blanqueador, lo que indica un consumo más selectivo.

Capitulo 7. Referencias

5arSanti/data-mining-eclat. (2025). GitHub. https://github.com/5arSanti/data-mining-eclat

Arias S. (2026). Parcial 2 Practico - Reglas de Asociacion (Mineria de Datos). https://colab.research.google.com/drive/1FRWW8kjhHL4VHf2WGZKlj0CFpA0l365h?usp=sharing

Arias S. (2026). Resultados de encuesta de mercado (Dataset) – Minería de Datos. https://1drv.ms/x/c/9cd239359a0de8d6/IQBs8Cy0d-eCT4SbIBajGUnuAd7EB6KiTgNPsAB1CxjXUu4?e=HzwyBw

Arias S. (2026). Dataframe procesado con productos binarizados. https://1drv.ms/x/c/9cd239359a0de8d6/IQA_uA8Kuap3To9qK_n6SeN0AeuRa1XnLmLOFBfmd1gTHRo?e=jqNEEQ